

Guía de Laboratorio Académico

Clasificación de Vibraciones con IA (TinyML)

MANUAL COMPLETO DE IMPLEMENTACIÓN Y VALIDACIÓN

Plataforma Tecnológica: Edge Impulse Cloud v3

Nivel Educativo: Ingeniería / Técnicos Superiores

Hardware Requerido: Acelerómetro Triaxial de Smartphone

Objetivo Principal: Detección de anomalías y estados mecánicos

Este documento constituye la guía oficial estructurada para el desarrollo autónomo de la práctica de Inteligencia Artificial periférica (TinyML). A través de este flujo de trabajo, el alumno capturará datos bio-mecánicos o industriales, configurará una arquitectura completa de procesamiento digital de señales (DSP) y entrenará una red neuronal profunda con optimización matemática de hardware.

FASE 1: Conexión del Dispositivo Sensor

Para la recolección de series temporales continuas, vincularemos el hardware físico directamente con el motor de ingesta de datos en la nube.

1. Acceda al panel de control del proyecto asignado en la plataforma de **Edge Impulse** a través del ordenador corporativo.
2. En la barra lateral derecha o en el menú de navegación, localice la sección interactiva titulada **"Collect data"**.
3. Haga clic sobre el enlace hipervínculo de color azul: **"Connect a device"**.
4. Seleccione la modalidad de hardware embebido denominada **"Use your phone"**, la cual desplegará un código QR dinámico y único en la interfaz de usuario.
5. Utilice el lector QR o la cámara nativa de su smartphone para escanear el código. Esto iniciará un socket seguro WebRTC que transformará los sensores del móvil en un nodo edge inalámbrico.

Nota Crítica de Continuidad de Red

Los alumnos deben mantener abierta y en primer plano la pestaña del navegador web del smartphone durante todo el transcurso de la sesión. Si el sistema operativo móvil suspende la pantalla o congela la aplicación, el enlace de telemetría de datos se interrumpirá inmediatamente de forma automática.

FASE 2: Captura de Datos y Configuración del Dataset

Un dataset equilibrado y correctamente estructurado es la base algorítmica para el aprendizaje óptimo del modelo. Se aplicarán estrictos criterios de etiquetado.

2.1 Ajustes del Formulario de Muestreo

Antes de iniciar la adquisición de cada ráfaga física, configure rigurosamente las siguientes propiedades dentro del bloque de captura del ordenador:

Parámetro Técnico	Valor / Entrada Exacta	Propósito y Justificación
Label (Etiqueta)	IDLE u VIB_FUERTE	Determina la clase de salida. Debe ingresarse estrictamente en mayúsculas, sin espacios ni caracteres especiales.
Sample length	5000 ms a 10000 ms	Tiempo de grabación (5-10 segundos). Duraciones menores no recopilan suficientes ciclos para extraer patrones frecuenciales.
Sensor Type	Accelerometer	Selección de los tres canales de inercia dinámicos (ejes X, Y, Z).
Category Split	Automatically split	Habilita el reparto algorítmico nativo: 80% Entrenamiento / 20% Pruebas (Test).

2.2 Metodología de Muestreo y Aumento de Variedad

Los alumnos realizarán un mínimo obligatorio de **10 capturas independientes por cada una de las clases**. Con el fin de dotar al modelo de resiliencia y evitar el sobreajuste ante factores ambientales del laboratorio, se ejecutará el siguiente protocolo de captura:

- **Clase de estado estacionario (IDLE)**: Registre las 10 muestras posando el smartphone de manera estática. Intercale diferentes soportes físicos (mesas de madera densa, encimeras metálicas, suelo de baldosa). Esto permite que la red aprenda a ignorar y abstraer el ruido blanco y las vibraciones parásitas de los edificios.
- **Clase de actividad crítica (VIB_FUERTE)**: Registre las 10 muestras provocando fuerzas inerciales variables. Modifique el patrón dinámico: introduzca sacudidas manuales de alta frecuencia, impactos rítmicos sobre el banco de pruebas o fije el dispositivo sobre un ordenador portátil con cargas de procesamiento elevadas que activen mecánicamente los ventiladores de refrigeración.

FASE 3: Diseño del Impulse (Arquitectura del Pipeline IA)

El "Impulse" conforma el flujo de procesamiento completo de TinyML, delimitando formalmente desde el procesado del vector de entrada hasta la capa probabilística final. Acceda a la pestaña **Impulse design** en el menú lateral izquierdo.

3.1 Bloque Temporal de Entrada (Time series data)

- **Window size:** Configure el parámetro en exactamente `2000 ms`. Esto indica que el modelo segmentará las muestras macro en ventanas continuas de 2 segundos para realizar sus inferencias.
- **Window increase:** Reduzca el incremento deslizante a `200 ms`. Esta técnica genera un solapamiento regular (*sliding window*), multiplicando exponencialmente la densidad de ejemplos de entrenamiento útiles.
- **Frequency (Hz):** Respete los `62.5 Hz` por defecto aportados por la tasa de refresco por hardware de los sensores móviles.

3.2 Bloque de Procesamiento Digital de Señal (DSP Block)

Haga clic en el botón *"Add a processing block"* y anexe el algoritmo de **Spectral Analysis**. Renómbrelo en la interfaz como `Analisis espectral`. Cerciórese de validar con un check azul los tres vectores espaciales de aceleración disponibles: *accX*, *accY* y *accZ*.

Fundamentación Científica: ¿Por qué Spectral Analysis en lugar de Raw Data?

Las oscilaciones procedentes de maquinaria real en entornos industriales son intrínsecamente caóticas y ruidosas en el dominio del tiempo. Al aplicar el procesamiento espectral, el sistema ejecuta una **Transformada Rápida de Fourier (FFT)**. Este proceso descompone el ruido en el espacio temporal y lo traslada al dominio de la frecuencia, aislando picos claros de potencia matemática en armónicos estables. Para una red neuronal convolucional o densa, es drásticamente más viable aprender "la firma armónica" que analizar la onda cruda directamente.

3.3 Bloque de Aprendizaje Profundo (Learning Block)

1. Haga clic sobre el nodo de conexión *"Add a learning block"*.
2. Seleccione e integre la opción estándar **Classification (Red Neuronal / Keras)**.
3. Verifique de forma analítica que el componente verde terminal (*Output features*) liste correctamente los dos estados previamente definidos: `IDLE` y `VIB_FUERTE`.
4. Guarde la configuración del pipeline pulsando el botón verde **"Save Impulse"**.

FASE 4: Extracción de Características y Análisis de Espacio de Estados

Una vez establecida la lógica estructural, es imperativo calcular los coeficientes espectrales individuales de todo el set de datos capturado.

1. En la barra lateral de navegación, acceda al submódulo nuevo rotulado como **Spectral features** (o su alias personalizado ``Análisis espectral``).
2. La interfaz mostrará la conversión por software de sus señales físicas. Sin alterar los coeficientes avanzados del filtro o de la longitud FFT, baje al término de la página y pulse el control azul **Save parameters**.
3. El sistema le redirigirá instantáneamente a la pestaña superior interna **Generate features**.
4. Dé inicio al proceso masivo haciendo clic sobre el botón verde **Generate features**. Un hilo de comandos en segundo plano procesará por completo los datos brutos.
5. **Análisis visual obligatorio para el alumno:** Al completarse el proceso, inspeccione el visor tridimensional interactivo **Feature Explorer**. Compruebe detalladamente que los clusters vectoriales de las muestras correspondientes a la etiqueta de reposo y de vibración fuerte estén perfectamente polarizados, limpios y segregados en nubes independientes de puntos.

FASE 5: Configuración y Entrenamiento del Clasificador (Red Neuronal)

El clasificador mapeará los patrones espectrales previamente computados hacia las clases de destino a través de optimizaciones numéricas sucesivas.

1. Seleccione el menú lateral **Classifier**.
2. Establezca los siguientes hiperparámetros de control en la ventana izquierda:

Hiperparámetro	Valor Asignado	Implicación Operacional
Number of training cycles (Epochs)	30	Ciclos completos en que el optimizador recorrerá el dataset completo. Balance equilibrado para eludir el subentrenamiento.
Learning rate (Tasa de aprendizaje)	0.0005	Magnitud del ajuste de los pesos sinápticos ante los gradientes de error calculados en el *backpropagation*.
Training processor	CPU	Hardware encargado del procesamiento.
Capas Ocultas Densas (Architecture)	Dense (20) → Dense (10)	Estructura interna compacta de capas totalmente conectadas, optimizada para su ejecución restrictiva en Microcontroladores.

1. Inicie el algoritmo de aprendizaje profundo presionando el botón verde *****Start training*****.
2. Analice el cuadro de trazas del log (*Training output*). El alumno observará cómo el indicador de pérdida disminuye matemáticamente hacia valores cercanos a cero con cada iteración.

5.1 Métricas de Rendimiento Interno Esperadas

Una vez concluido el ciclo de entrenamiento número 30, el sistema mostrará los resultados de la validación interna. El alumno debe constatar:

- **Accuracy (Precisión de validación):** Debe situarse idealmente en valores cercanos al **100.0%**, tolerándose métricas por encima del 90% para validar un entorno experimental correcto.
- **Loss (Pérdida):** Un valor límite cercano a **0.00** que indica la perfecta convergencia matemática del optimizador.
- **Confusion Matrix (Matriz de Confusión):** La diagonal de aciertos cruzados debe exhibir el 100% de eficacia, certificando que ninguna ventana de datos pertenecientes a reposo fue falsamente asignada a vibración de alta intensidad.

FASE 6: Validación Final Ciega (Model Testing)

La validación real en Machine Learning exige someter al modelo ante datos completamente inéditos que jamás participaron en las fases previas de ajuste de los pesos sinápticos.

1. Haga clic en la opción ****Model testing**** situada en el menú principal izquierdo de Edge Impulse.
2. En la pantalla central se visualizarán de manera exclusiva las muestras pertenecientes al **20% de datos de prueba** aislados durante el proceso de captura inicial de la Fase 2.
3. Presione el botón verde superior rotulado como *****Classify all*****.

4. El motor inferencial computará la respuesta del modelo en fracciones de segundo y actualizará los resultados generales del proyecto.

Dictamen Final y Certificación de Éxito

Si la métrica de ****Accuracy global**** del examen ciego se consolida en una tasa del **100.00%** (o valores homólogos muy elevados), se extiende la certificación formal de aptitud del modelo. Queda científicamente demostrado que el sistema ha asimilado las dinámicas frecuenciales del fenómeno físico en lugar de memorizar muestras individuales, descartando por completo el riesgo de **overfitting (sobreajuste)**. El firmware resultante es óptimo para su posterior compilación C++ directa y despliegue real en sensores de mantenimiento predictivo de plantas industriales.